

Część I: obrazy jako cechy

Obrazy z dwóch wybranych klas

- 0 - samoloty
- 1 - samochody




Najlepsze wyniki dla podejścia z wektorami:
Liczba sąsiadów: 1
Dokładność klasyfikacji: 0.715

Najlepsze wyniki dla podejścia z histogramami:
Liczba sąsiadów: 9
Dokładność klasyfikacji: 0.7775

wyniki dla najlepszej wersji - histogramy 9 sąsiadów

Przykłady z klasy 1 i ich sąsiedzi:

Przykład 1



Przykład 2

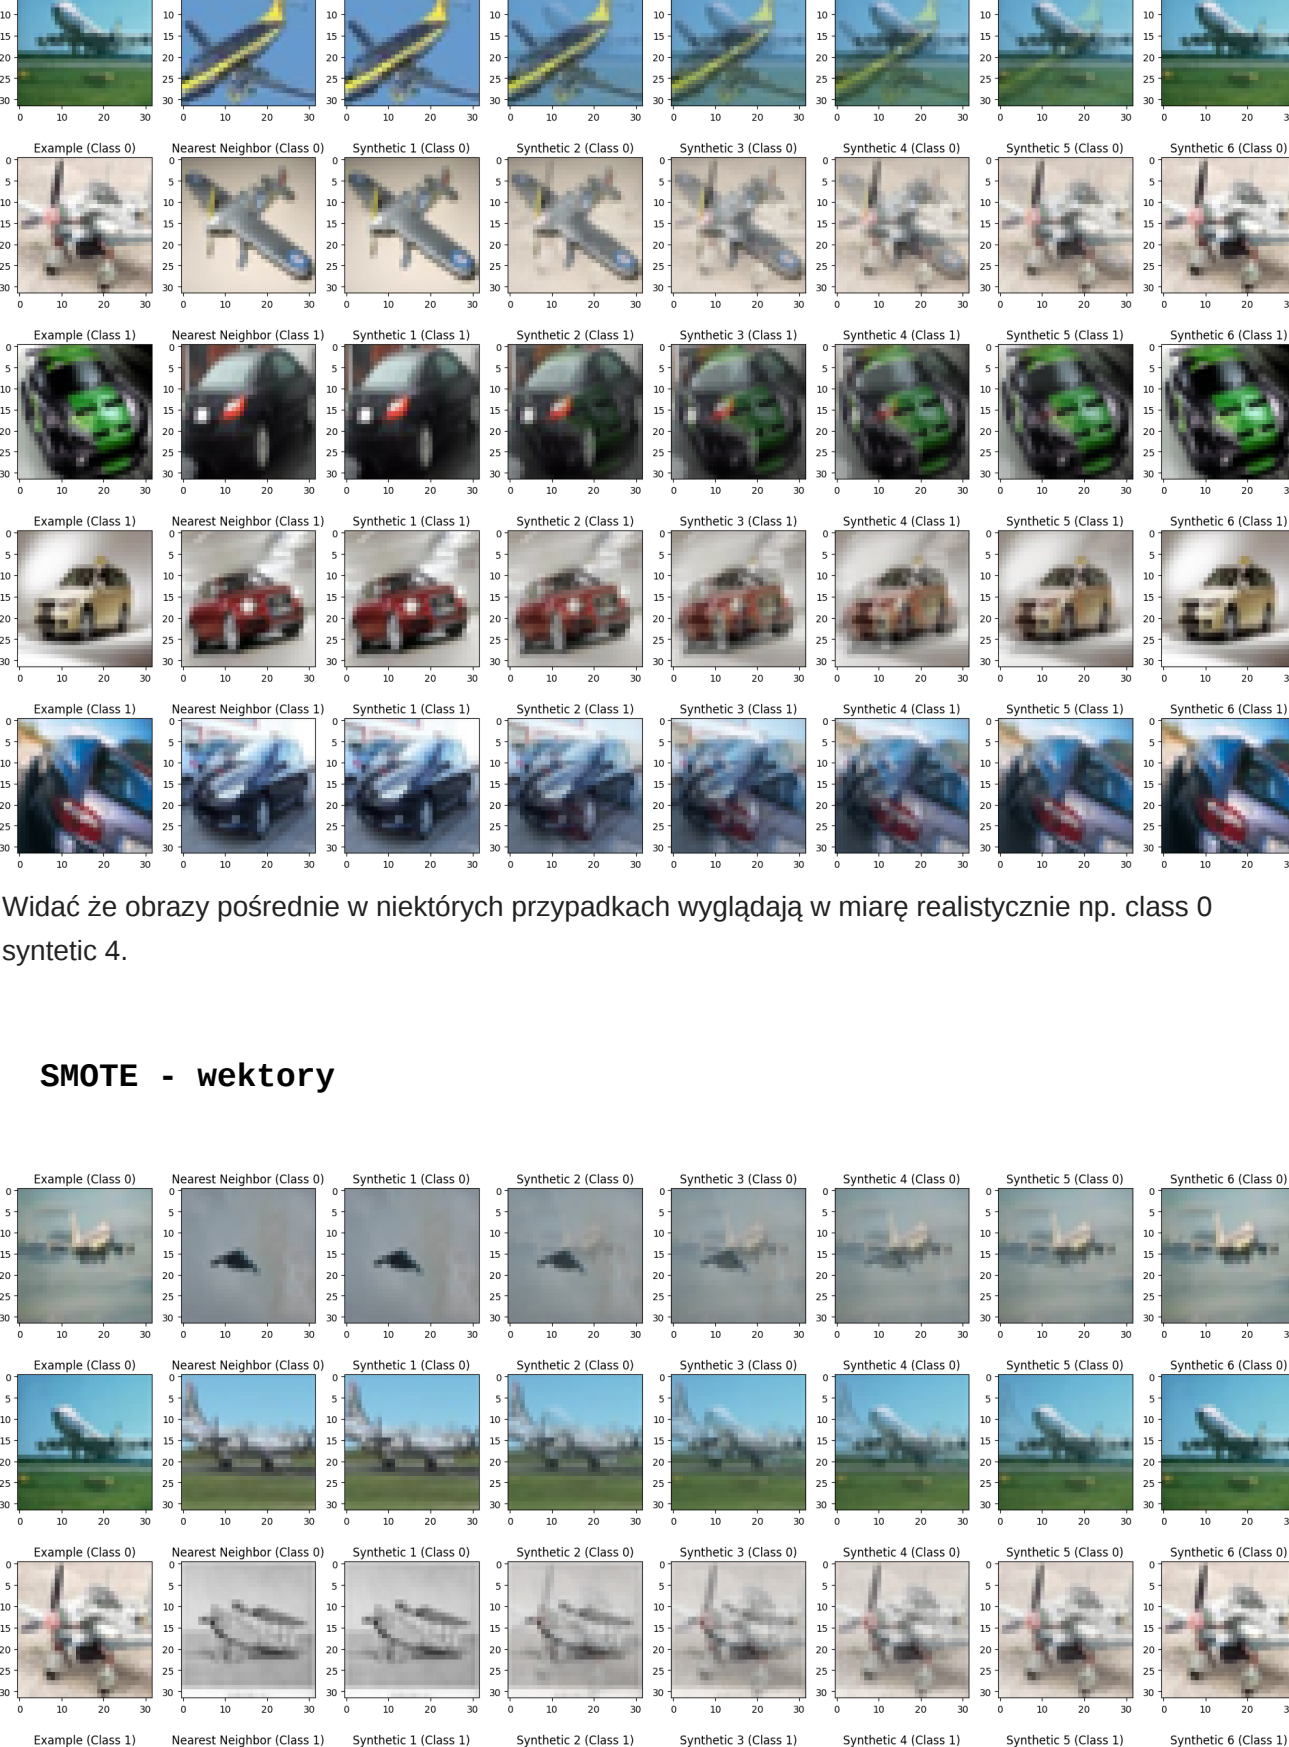


Przykład 3



Wyniki mimo, że nie zawsze są poprawne to zawsze wydają się być bardzo sensowne. Widać że algorytm skupił się przede wszystkim na aspektach kolorystycznych (oprócz klasa 1 przykład 3 gdzie mogło być brane bardziej ułożenie obiektów)

SMOTE - histogramy



Widać że obrazy pośrednie w niektórych przypadkach wyglądają w miarę realistycznie np. class 0 syntetyc 4.

SMOTE - wektory



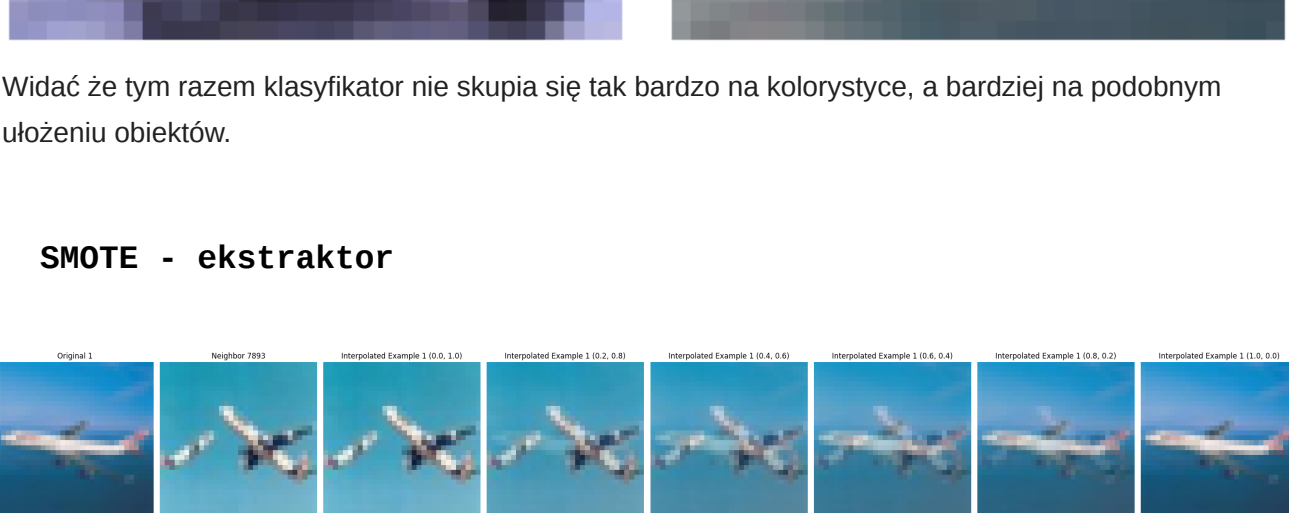
W przypadku drugiej metody - wektory wyniki są gorsze i widać że obrazy pośrednie też są mniej realistyczne.

Część II: konwolucyjny ekstraktor cech

Najlepsze wyniki dla podejścia z ekstraktorem:
Liczba sąsiadów: 7
Dokładność klasyfikacji: 0.6785

Uzyskane wyniki są nieco gorsze od poprzednich ale różnica nie jest duża - ok 5% gorzej niż wersja z wektorami poprzednio.

Znalezieni sąsiedzi:



Widać że tym razem klasyfikator nie skupia się tak bardzo na kolorystyce, a bardziej na podobnym ułożeniu obiektów.

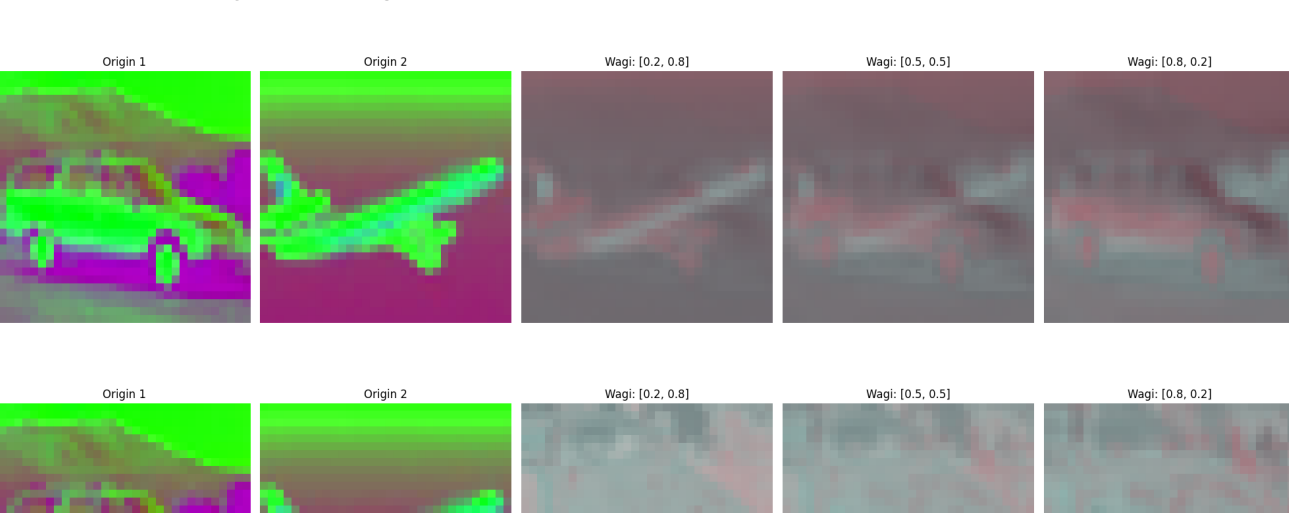
SMOTE - ekstraktor



Przez mniejszą dokładność wyników widać większe rozbieżności w stosunku z poprzednią metodą, natomiast przez to, że bardziej brane jest pod uwagę umieszczenie obiektu na obrazku w niektórych przykładach (1 i 2) efekty połączenia są zadowalające.

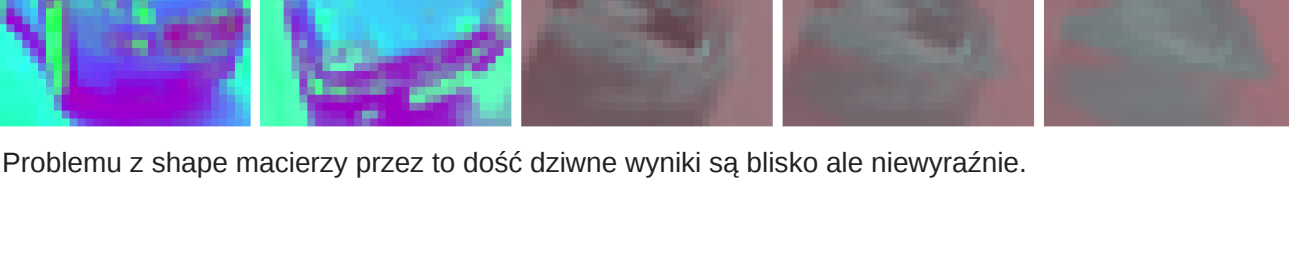
Część III: ukryci sąsiedzi

Przykładowe rekonstrukcje encodera dla tego samego zdjęcia



W zależności od parametru 'latent_dim' można poprawić jakość - większe to lepsza jakość.

Znalezieni sąsiedzi wykonanie SMOTE



Problemu z shape macierzy przez to dość dziwne wyniki są blisko ale niewyraźnie.